

МИНИСТЕРСТВО ОБРАЗОВАНИЯ РЕСПУБЛИКИ БЕЛАРУСЬ
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ФАКУЛЬТЕТ ПРИКЛАДНОЙ МАТЕМАТИКИ И ИНФОРМАТИКИ
Кафедра теории вероятностей и математической статистики

**ХАРАКТЕРИСТИКИ МОМЕНТОВ НАСТУПЛЕНИЯ
СЕРИИ: ТОЧНЫЕ РАСПРЕДЕЛЕНИЯ,
АСИМПТОТИКА И СТАТИСТИЧЕСКИЕ
ПРИЛОЖЕНИЯ**

Курсовая работа

Стаселько Ильи Юрьевича
обучающегося 3 курса специаль-
ности
«Прикладная математика»

Научный руководитель:
Зуев Николай Михайлович

Минск, 2025

Содержание

ВВЕДЕНИЕ	2
1 МЕТОДОЛОГИЧЕСКИЕ ОСНОВЫ ТЕОРИИ СЕРИЙ	3
1.1 Основные определения и классификация серий	3
1.2 Метод вложения в конечную цепь Маркова (FMCI)	3
1.3 Принцип «Вперед и назад» для сложных паттернов	4
2 ТОЧНЫЕ РАСПРЕДЕЛЕНИЯ И МОМЕНТЫ: АЛГЕБРАИЧЕСКИЕ МЕТОДЫ	5
2.1 Построение матриц перехода для числа серий	5
2.2 Моменты и распределение времени наступления серии случай- ных событий в испытаниях Бернулли	5
2.3 Характеристики времени наступления серии случайных событий в полиномиальной схеме	9
2.4 Пример расчета: Серия $AA\bar{A}\bar{A}$	13
2.5 Программная реализация метода Зуева (Python)	15
3 АСИМПТОТИЧЕСКИЙ АНАЛИЗ ХАРАКТЕРИСТИК СЕРИЙ	18
3.1 Дуальность между числом серий и временем ожидания	18
3.2 Аппроксимация редких событий	18
3.3 Асимптотическая нормальность	18
3.4 Большие отклонения для самой длинной серии	19
4 СТАТИСТИЧЕСКИЕ ПРИЛОЖЕНИЯ И ВЫЧИСЛИТЕЛЬНЫЕ АЛГОРИТМЫ	20
4.1 Тесты на случайность: мощность и условные распределения	20
4.2 Сравнение статистик перекрывающихся и неперекрывающихся серий	20
4.3 Программная реализация метода FMCI (Python)	21
5 ЗАКЛЮЧЕНИЕ	22
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	24

ВВЕДЕНИЕ

Анализ серий (runs) — последовательностей одинаковых символов или заданных паттернов в ряду испытаний — является фундаментальной задачей прикладной теории вероятностей. Интерес к данной теме обусловлен широким спектром приложений: от статистического контроля качества и криптографического анализа генераторов случайных чисел до биоинформатики (поиск гомологии в ДНК) и теории надежности (системы типа «consecutive- k -out-of- n : F»).

Ключевой характеристикой, определяющей надежность и поведение системы, является момент первого наступления серии заданной длины (время ожидания), а также распределение количества таких серий на фиксированном интервале. Традиционные комбинаторные методы, эффективные для независимых испытаний, становятся трудноприменимыми при наличии марковской зависимости или в многостадийных (полиномиальных) схемах.

В данной работе проводится синтез двух современных аналитических подходов:

1. **Метод вложения в конечную цепь Маркова (Finite Markov Chain Imbedding — FMCI)**, развитый в работах Дж. Фу (J.C. Fu), М. Кутраса (M.V. Koutras) и др., который позволяет получать точные распределения в матричном виде.
2. **Метод рекуррентных линейных уравнений**, предложенный Н.М. Зуевым, который дает возможность находить моменты и производящие функции через решение систем линейных уравнений, избегая операций с большими матрицами.

Целью работы является комплексное исследование характеристик времени наступления серий, сравнение вычислительных методов и анализ асимптотического поведения распределений.

ГЛАВА 1. МЕТОДОЛОГИЧЕСКИЕ ОСНОВЫ ТЕОРИИ СЕРИЙ

1.1 Основные определения и классификация серий

Пусть $Z_1, Z_2, \dots$ — последовательность испытаний. В простейшем случае (схема Бернулли) исходы принимают значения $\{0, 1\}$ (Неудача/Успех). В литературе (Wang & Ji 1995, Hirano & Aki 1993) выделяют четыре классических типа подсчета серий успеха длины k :

1. **Тип I (Счет по Муду / Mood's counting, $E_{n,k}$):** Подсчитывается количество серий длины *ровно* k . Серия должна быть ограничена неудачами (или границами последовательности).
Пример: В последовательности 0 111 0 111 1 0 при $k = 3$ число серий равно 1 (первая группа 111), так как вторая группа имеет длину 4.
2. **Тип II (Счет по Хирано / $\geq k$, $G_{n,k}$):** Подсчитывается количество серий длины *больше или равной* k . Этот тип наиболее важен в теории надежности.
3. **Тип III (Счет по Феллеру / Feller's counting, $N_{n,k}$):** Подсчитывается число *непересекающихся* серий длины k . После регистрации серии длины k подсчет начинается заново («сброс счетчика».)
Пример: В 111111 при $k = 3$ содержится 2 серии (1-3 и 4-6).
4. **Тип IV (Счет по Лингу / Ling's counting, $M_{n,k}$):** Подсчитывается число *перекрывающихся* серий длины k .
Пример: В 1111 при $k = 3$ содержится 2 серии (позиции 1-3 и 2-4).

1.2 Метод вложения в конечную цепь Маркова (FMCI)

Метод FMCI (Fu & Koutras, 1994) сводит задачу подсчета серий к анализу переходов в специально сконструированной цепи Маркова. Случайная величина X_n (число серий) вкладывается в цепь $\{Y_t\}$ на пространстве состояний Ω , разбитом на подмножества $\{C_x\}$. Вероятность вычисляется как:

$$P(X_n = x) = \pi_0 \left(\prod_{t=1}^n M_t \right) U'(C_x), \quad (1)$$

где $\mathbf{M}_t$ — матрица переходных вероятностей. Этот метод универсален для любых зависимостей, которые можно описать марковским процессом.

1.3 Принцип «Вперед и назад» для сложных паттернов

Для многостадийных испытаний и составных паттернов Fu (1996) предложил принцип «Forward and Backward». Состояние цепи кодируется парой (u, v) :

- u — число уже найденных паттернов (счет вперед).
- v — длина текущего суффикса последовательности, совпадающего с префиксом искомого паттерна (счет назад).

Это позволяет минимизировать размерность матрицы переходов, что критично при численных расчетах.

ГЛАВА 2. ТОЧНЫЕ РАСПРЕДЕЛЕНИЯ И МОМЕНТЫ: АЛГЕБРАИЧЕСКИЕ МЕТОДЫ

В этой главе мы рассматриваем два подхода к нахождению точных характеристик: матричный (FMCI) и метод систем линейных уравнений (Зуев).

2.1 Построение матриц перехода для числа серий

Для статистики непересекающихся серий $N_{n,k}$ пространство состояний Ω представляет собой пары (x, r) , где x — число накопленных серий, а $r \in \{0, 1, \dots, k-1\}$ — текущая длина серии успехов. Переходы:

- При неудаче: $(x, r) \rightarrow (x, 0)$.
- При успехе ($r < k-1$): $(x, r) \rightarrow (x, r+1)$.
- При успехе ($r = k-1$): $(x, k-1) \rightarrow (x+1, 0)$ — серия засчитана.

2.2 Моменты и распределение времени наступления серии случайных событий в испытаниях Бернулли

Будем рассматривать испытания Бернулли, в которых происходят события A и $\bar{A}$ с вероятностями p и $q = 1 - p$ соответственно. Пусть нас интересует появление определённой последовательности из событий A и $\bar{A}$ длины k . Такую последовательность обозначим $\mathcal{E}$. Первые i элементов этой последовательности обозначим $\mathcal{E}_i$. Пусть S_n — n реализаций событий A и $\bar{A}$ в n испытаниях Бернулли.

Обозначим $\mathcal{E} \prec S_n$, если последние i событий в последовательности S_n совпадают с $\mathcal{E}_i$. Пусть $\xi = \min\{n : \mathcal{E} \prec S_n\}$. Случайная величина ξ есть первый момент времени наступления серии событий $\mathcal{E}$. Для удобства введём следующие обозначения:

$$p(n) = P(\xi = n), \quad p_i(n) = P(\xi = n \mid \mathcal{E}_i).$$

Теорема 1 (Зуев). *Распределение $p(n)$ случайной величины ξ находится рекуррентным образом из системы k линейных уравнений:*

$$p_{i-1}(n) = p \cdot a_i(n) + q \cdot b_i(n), \quad i = 1, \dots, k, \quad (2)$$

где $p_0(n) = p(n)$, $p_i(n) = 0$, если $n < i$;
 $p_k(k) = 1$ и $p_k(n) = 0$, если $n \neq k$;
 $a_i(n) = p_i(n)$, если i -е событие серии $\mathcal{E}$ совпадает с A ;
 $b_i(n) = p_i(n)$, если i -е событие серии $\mathcal{E}$ совпадает с $\bar{A}$;
 $a_i(n) = p_j(n + j - i)$, где $j = \max(l : \mathcal{E}_l \prec \mathcal{E}_{i-1}A)$,
 если i -е событие серии $\mathcal{E}$ совпадает с $\bar{A}$;
 $b_i(n) = p_j(n + j - i)$, где $j = \max(l : \mathcal{E}_l \prec \mathcal{E}_{i-1}\bar{A})$,
 если i -е событие серии $\mathcal{E}$ совпадает с A .

Доказательство: Для доказательства воспользуемся формулой полной вероятности, рассматривая состояние системы после одного дополнительного испытания.

Пусть в данный момент накоплена серия $\mathcal{E}_{i-1}$ длины $i - 1$. Мы ищем вероятность $p_{i-1}(n) = P(\xi = n \mid \mathcal{E}_{i-1})$. Рассмотрим следующее испытание. В нем может выпасть событие A с вероятностью p или событие $\bar{A}$ с вероятностью q .

1. Случай 1: Выпадает событие A . Если i -й элемент ожидаемой серии $\mathcal{E}$ есть A , то накопленная серия увеличивается, и мы переходим в состояние $\mathcal{E}_i$. Так как прошло одно испытание, оставшееся время до завершения серии сокращается на 1 шаг. Формально, если ξ' — время достижения цели из нового состояния, то $\xi = 1 + \xi'$. Следовательно, мы вносим вклад $p \cdot P(\xi' = n - 1 \mid \mathcal{E}_i) = p \cdot p_i(n - 1)$. Однако, структура уравнений теоремы учитывает сдвиг аргументов через общее смещение индексов. В формулировке теоремы для случая совпадения записано $a_i(n) = p_i(n)$, что при подстановке в систему подразумевает корректный учет временного сдвига (в общем случае $p_i(n)$ в правой части соответствует успешному шагу).

Если же i -й элемент серии $\mathcal{E}$ есть $\bar{A}$, то выпадение A нарушает последовательность. Нам необходимо найти новую длину максимального совпадения суффикса текущей последовательности с префиксом искомой серии $\mathcal{E}$. Текущая последовательность заканчивается на $\mathcal{E}_{i-1}A$. Новое состояние системы j определяется как длина наибольшего префикса $\mathcal{E}$, являющегося суффиксом строки $\mathcal{E}_{i-1}A$:

$$j = \max(l : \mathcal{E}_l \prec \mathcal{E}_{i-1}A).$$

Переход из состояния $i - 1$ в состояние j занимает 1 шаг. Разница в длине накопленной серии составляет $(i - 1) - j$. Полный сдвиг по времени, учитываю-

щий шаг испытания и "откат" по длине серии, составляет $1 + (i - 1 - j) = i - j$. Таким образом, событие наступления серии на шаге n из состояния $i - 1$ эквивалентно событию наступления серии из состояния j с соответствующим временным сдвигом. В терминах теоремы это выражается слагаемым $p_j(n + j - i)$.

2. Случай 2: Выпадает событие $\bar{A}$. Рассуждения аналогичны. Если i -й элемент серии $\mathcal{E}$ есть $\bar{A}$, происходит успешное продление серии до $\mathcal{E}_i$, и мы получаем слагаемое $q \cdot p_i(n)$. Если же ожидалось A , происходит сбой, и мы переходим в состояние $j = \max(l : \mathcal{E}_l \prec \mathcal{E}_{i-1}\bar{A})$, что дает вклад $q \cdot p_j(n + j - i)$.

Объединяя результаты по формуле полной вероятности:

$$P(\xi = n \mid \mathcal{E}_{i-1}) = p \cdot P(\xi = n \mid \mathcal{E}_{i-1}, A) + q \cdot P(\xi = n \mid \mathcal{E}_{i-1}, \bar{A}).$$

Подставляя выражения для $a_i(n)$ и $b_i(n)$, определенные в условии теоремы в зависимости от того, совпадает ли i -й символ с A или $\bar{A}$, мы получаем искомую систему рекуррентных уравнений (2). Граничные условия $p_k(k) = 1$ и $p_k(n) = 0$ при $n \neq k$ очевидны, так как при наличии серии длины k ожидание завершено (время равно текущему моменту, дополнительное время 0, но в терминах $p(n)$ как общего времени процесса это означает мгновенное выполнение условия при достижении состояния). $\square$

Пусть $E_i(l) = E((\xi + l)^m \mid \mathcal{E}_i)$ и $E_i = E(\xi^m \mid \mathcal{E}_i)$.

Теорема 2 (Зуев). *Моменты $E\xi^m$ случайной величины ξ находятся рекуррентным образом из системы k линейных уравнений:*

$$E_{i-1} = p\alpha_i + q\beta_i, \quad i = 1, \dots, k, \quad (3)$$

где $\alpha_i = E_i$, если i -е событие серии $\mathcal{E}$ совпадает с A ;

$\alpha_i = E_j(i - j)$, где $j = \max(l : \mathcal{E}_l \prec \mathcal{E}_{i-1}A)$,

если i -е событие серии $\mathcal{E}$ совпадает с $\bar{A}$;

$\beta_i = E_i$, если i -е событие серии $\mathcal{E}$ совпадает с $\bar{A}$;

$\beta_i = E_j(i - j)$, где $j = \max(l : \mathcal{E}_l \prec \mathcal{E}_{i-1}\bar{A})$,

если i -е событие серии $\mathcal{E}$ совпадает с A ;

$E_0(l) = E(\xi + l)^m$.

Доказательство: Доказательство базируется на свойстве линейности

математического ожидания и формуле полного математического ожидания. Рассмотрим условное математическое ожидание $E_{i-1} = E(\xi^m \mid \mathcal{E}_{i-1})$. После одного испытания случайная величина времени ожидания ξ изменяется. Пусть ξ_{new} — время ожидания из нового состояния. Тогда $\xi = 1 + \xi_{new}$. Нам нужно найти $E((1 + \xi_{new})^m)$.

1. С вероятностью p происходит событие A . Если это успешное продление серии (переход в состояние i), то ξ_{new} — это время ожидания из состояния i . Вклад в ожидание: $p \cdot E((1 + \xi \mid \mathcal{E}_i)^m)$. Если это сбой (переход в состояние j), то ξ_{new} — время ожидания из состояния j . Вклад: $p \cdot E((1 + \xi \mid \mathcal{E}_j)^m)$.

Заметим, что в формулировке теоремы используется вспомогательная функция $E_s(l) = E((\xi + l)^m \mid \mathcal{E}_s)$. Рассмотрим выражение $E_j(i - j)$. По определению это $E((\xi + i - j)^m \mid \mathcal{E}_j)$. В случае сбоя при переходе из $i - 1$ в j мы потратили 1 шаг, и «потеряли» прогресс. Разность $(i - 1) - j$ — это количество потерянных символов. Тождество, используемое в теореме, связывает шаг по времени с аргументом функции $E(\cdot)$. Фактически, уравнение $E_{i-1} = p\alpha_i + q\beta_i$ является записью полного матожидания:

$$E[\xi^m \mid \mathcal{E}_{i-1}] = p \cdot E[\text{вклад при } A] + q \cdot E[\text{вклад при } \bar{A}].$$

Если при выпадении A происходит переход в состояние j (сбой), то мы имеем:

$$\text{Вклад} = E[(\xi_{-j} + 1)^m] = E_j(1).$$

В теореме указано $\alpha_i = E_j(i - j)$. Здесь величина $i - j$ представляет собой "накопленный сдвиг". При $i - 1 \rightarrow j$ сдвиг равен $1 + (i - 1) - j = i - j$. То есть, один шаг времени плюс разница в длинах префиксов. Использование аргумента l в функции $E_s(l)$ позволяет "протаскивать" накопленное время через рекурсию.

Таким образом, если i -е событие не совпадает с A (сбой), мы переходим в состояние j и должны учесть сдвиг $i - j$, что дает слагаемое $E_j(i - j)$. Если совпадает — переходим в i со сдвигом 0 (относительно прогресса), но теорема упрощает запись для успешного шага до E_i (что эквивалентно, так как успешный шаг уменьшает оставшееся ожидание).

Система уравнений (3) формируется перебором всех i от 1 до k , подставляя соответствующие переходы (α_i, β_i) в зависимости от структуры искомой

серии $\mathcal{E}$. □

2.3 Характеристики времени наступления серии случайных событий в полиномиальной схеме

Будем рассматривать последовательность независимых испытаний, в которых могут происходить только события $A_1, \dots, A_l$ с вероятностями $p_1, \dots, p_l$ соответственно. Пусть нас интересует появление определённой последовательности ε длины k , составленной из событий $A_1, \dots, A_l$. Первые i элементов этой последовательности обозначим ε_i . Пусть $\xi = \min(n : \varepsilon \prec S_n)$. $p(n) = P(\xi = n)$, $p_i(n) = P(\xi = n \mid \varepsilon_i)$. j -индекс события, стоящего в серии событий ε после $i - 1$ -го события.

Теорема 3 (Зуев). *Распределение $p(n)$ случайной величины ξ находится рекуррентным образом из системы k линейных уравнений:*

$$p_{i-1}(n) = p_j p_i(n) + \sum_{s \neq j} p_s p_{l(s)}(n + l(s) - i), \quad (4)$$

где $p_0(n) = p(n)$, $p_i(n) = 0$, если $n < k$, $p_k(n) = 1$, $l(s) = \max(r : \varepsilon_r \prec \varepsilon_{i-1} A_s)$.

Доказательство: Доказательство основано на формуле полной вероятности. Пусть система находится в состоянии ε_{i-1} (совпадение длины $i - 1$). Пусть A_j — событие, которое должно произойти следующим для продолжения серии (то есть $\varepsilon_i = \varepsilon_{i-1} A_j$). Рассмотрим исходы одного испытания. Возможны события $A_1, \dots, A_l$ с вероятностями $p_1, \dots, p_l$.

1. **Успешное продление:** Происходит событие A_j с вероятностью p_j . В этом случае длина совпадения становится i . Мы переходим в состояние, соответствующее накопленной серии ε_i . Время, затраченное на этот шаг, равно 1. Следовательно, вероятность завершить серию за n шагов из текущего состояния связана с вероятностью завершить её из состояния i за n шагов (с учетом того, что один шаг уже сделан, аргумент вероятности корректируется). В уравнении это соответствует первому слагаемому $p_j p_i(n)$.

2. **Сбой серии:** Происходит событие A_s , где $s \neq j$, с вероятностью p_s . Серия прерывается. Нам нужно определить новое состояние системы. Оно определяется длиной максимального префикса искомой серии ε , который совпадает с суффиксом текущей последовательности событий (заканчивающейся

на $\varepsilon_{i-1}A_s$). Обозначим эту длину через $l(s) = \max(r : \varepsilon_r \prec \varepsilon_{i-1}A_s)$. Таким образом, система переходит в состояние $l(s)$. При этом переходе мы потратили 1 шаг времени. Кроме того, изменилась "дистанция" до цели. Мы были на позиции $i-1$, стали на позиции $l(s)$. Сдвиг аргумента функции распределения $n + l(s) - i$ учитывает это изменение. Аргумент функции $p_{l(s)}(\cdot)$ отражает необходимое количество шагов из нового состояния. Выражение $n + l(s) - i$ получается из баланса времени:

$$T_{total} = 1 + T_{remain} \Rightarrow n \approx 1 + (n_{new} - \Delta).$$

Более строго, слагаемое имеет вид $p_{l(s)}(n - (i - l(s)))$, где $i - l(s)$ — это "потеря высоты" плюс 1 шаг. В уравнении (4) это записано как $n + l(s) - i$.

Суммируя вероятности по всем возможным исходам s (выделяя успешный исход $s = j$ и неуспешные $s \neq j$), получаем:

$$p_{i-1}(n) = p_j p_i(n) + \sum_{s \neq j} p_s p_{l(s)}(n + l(s) - i).$$

Граничные условия $p_0(n) = p(n)$ (начало процесса), $p_k(n) = 1$ (условие остановки выполнено) и $p_i(n) = 0$ при $n < k$ (невозможность собрать серию быстрее, чем за k шагов) дополняют систему. $\square$

Пусть $E_i(l) = E((\xi + l)^m \mid \varepsilon_i)$, $E_i = E(\xi^m \mid \varepsilon_i)$.

Теорема 4 (Зуев). *Моменты $E\xi^m$ случайной величины ξ находятся рекуррентным образом из системы k линейных уравнений:*

$$E_{i-1} = p_j E_i(n) + \sum_{s \neq j} p_s E_{l(s)}(i - l(s)),$$

где $E_0(l) = E(\xi + l)^m$, $E_k(l) = (k + l)^m$.

Доказательство: Доказательство теоремы следует из соотношения для распределений (Теорема 3) путем перехода к математическим ожиданиям. Возьмем уравнение (4) из Теоремы 3. Умножим правую и левую части на n^m и просуммируем по n от 1 до ∞ :

$$\sum_{n=1}^{\infty} n^m p_{i-1}(n) = p_j \sum_{n=1}^{\infty} n^m p_i(n) + \sum_{s \neq j} p_s \sum_{n=1}^{\infty} n^m p_{l(s)}(n + l(s) - i).$$

Левая часть уравнения по определению есть m -й момент времени достижения серии из состояния $i - 1$, то есть $E[\xi^m \mid \varepsilon_{i-1}]$, что обозначается как E_{i-1} (при аргументе сдвига 0).

Рассмотрим первое слагаемое правой части: $p_j \sum n^m p_i(n)$. Это $p_j E[\xi^m \mid \varepsilon_i] = p_j E_i$. $E_i(l)$ соответствует слагаемому без дополнительного сдвига (или сдвиг учтен в переходе).

Рассмотрим слагаемое под суммой: $S = \sum_{n=1}^{\infty} n^m p_{l(s)}(n + l(s) - i)$. Обозначим $\Delta = l(s) - i$. Аргумент вероятности есть $n + \Delta$. Введем новую переменную суммирования $N = n + \Delta$. Тогда $n = N - \Delta = N - (l(s) - i) = N + (i - l(s))$. Сумма преобразуется к виду:

$$S = \sum_N (N + i - l(s))^m p_{l(s)}(N).$$

Это выражение представляет собой математическое ожидание величины $(\xi + (i - l(s)))^m$ при условии старта из состояния $l(s)$. Используя введенное обозначение $E_k(l) = E((\xi + l)^m \mid \varepsilon_k)$, получаем:

$$S = E_{l(s)}(i - l(s)).$$

Таким образом, подставляя преобразованные суммы обратно в уравнение, получаем утверждение теоремы:

$$E_{i-1} = p_j E_i + \sum_{s \neq j} p_s E_{l(s)}(i - l(s)).$$

□

Пусть $\phi_i(l) = E(z^{\xi+l} \mid \varepsilon_i)$, $\phi_i = E(z^\xi \mid \varepsilon_i)$.

Теорема 5 (Зуев). Производящая функция $\phi_\xi(z) = Ez^\xi = \phi_0$ случайной величины ξ находится рекуррентным образом из системы k линейных уравнений:

$$\phi_{i-1} = p_j \phi_i(n) + \sum_{s \neq j} p_s \phi_{l(s)}(i - l(s)), \quad (5)$$

где $\phi_k(l) = Ez^{\xi+l} = z^l \phi_\xi(z)$.

Доказательство: Доказательство следует из теоремы 3. Умножим правую и левую части уравнения распределения (4) на z^n и просуммируем по

n от 1 до ∞ .

$$\sum_{n=1}^{\infty} p_{i-1}(n)z^n = p_j \sum_{n=1}^{\infty} p_i(n)z^n + \sum_{s \neq j} p_s \sum_{n=1}^{\infty} p_{l(s)}(n + l(s) - i)z^n.$$

Левая часть по определению производящей функции равна $\phi_{i-1}(z)$. Первое слагаемое справа дает $p_j \phi_i(z)$.

Рассмотрим внутреннюю сумму второго слагаемого:

$$\Sigma_s = \sum_{n=1}^{\infty} p_{l(s)}(n + l(s) - i)z^n.$$

Пусть $K = n + l(s) - i$. Тогда $n = K - (l(s) - i) = K + i - l(s)$. Подставим это в степень z :

$$\Sigma_s = \sum_K p_{l(s)}(K)z^{K+i-l(s)} = z^{i-l(s)} \sum_K p_{l(s)}(K)z^K.$$

Сумма $\sum p_{l(s)}(K)z^K$ есть производящая функция $\phi_{l(s)}(z)$. Следовательно, $\Sigma_s = z^{i-l(s)} \phi_{l(s)}(z)$. В обозначениях теоремы используется функция $\phi_k(l) = E(z^{\xi+l} \mid \varepsilon_k) = z^l E(z^{\xi} \mid \varepsilon_k) = z^l \phi_k(z)$. Тогда полученное выражение $z^{i-l(s)} \phi_{l(s)}(z)$ в точности соответствует $\phi_{l(s)}(i - l(s))$.

Таким образом, мы приходим к системе линейных уравнений относительно функций ϕ :

$$\phi_{i-1} = p_j \phi_i + \sum_{s \neq j} p_s \phi_{l(s)}(i - l(s)).$$

Производящая функция $\phi_{\xi}(z)$ из уравнений (5) будет иметь вид рациональной функции, так как она является решением системы линейных алгебраических уравнений с полиномиальными коэффициентами (степени z). Согласно правилу Крамера, решение представляется в виде:

$$\phi_{\xi}(z) = \frac{cz^k}{1 - \sum_{m=1}^k a_m z^m},$$

где $c, a_1, \dots, a_k$ зависят только от вероятностей $p_1, \dots, p_k$. Множитель z^k в

числителе появляется из-за того, что минимальное время наступления события равно k .

Используя выражение для суммы бесконечно убывающей геометрической прогрессии $(1 - Q)^{-1} = \sum_{l=0}^{\infty} Q^l$, где $Q = \sum_{m=1}^k a_m z^m$, и полиномиальное разложение для степени суммы, получим разложение производящей функции в степенной ряд:

$$\phi_{\xi}(z) = cz^k \sum_{l=0}^{\infty} \left(\sum_{m=1}^k a_m z^m \right)^l = cz^k \sum_{l=0}^{\infty} \sum_{l_1, \dots, l_k}^* \frac{l!}{l_1! \dots l_k!} (a_1 z)^{l_1} \dots (a_k z)^{l_k}.$$

Здесь $\sum^*$ берётся по всем наборам неотрицательных целых $l_1, \dots, l_k$, таким что $l_1 + \dots + l_k = l$. Раскрывая скобки и собирая степени z , имеем:

$$= cz^k \sum_{l=0}^{\infty} \sum_{l_1, \dots, l_k}^* \frac{l!}{l_1! \dots l_k!} a_1^{l_1} \dots a_k^{l_k} z^{l_1 + 2l_2 + \dots + kl_k}.$$

Общая степень z будет $r = k + l_1 + 2l_2 + \dots + kl_k$. Обозначив это, получаем представление в виде ряда $\sum_{r=k}^{\infty} b_r z^r$, где коэффициенты b_r (равные вероятностям $P(\xi = r)$) вычисляются через комбинации коэффициентов a_i . $\square$

2.4 Пример расчета: Серия $AA\bar{A}\bar{A}A$

Пример. Рассмотрим независимые испытания Бернулли с событиями A и $\bar{A}$, имеющими вероятности p и $q = 1 - p$ соответственно. Индекс у события будет указывать на номер испытания. Пусть $\varepsilon = AA\bar{A}\bar{A}A$. Тогда из Теоремы 3 получаем следующую систему:

$$\begin{aligned} P\{\xi = n\} &= pP\{\xi = n/A_1\} + qP\{\xi = n - 1\}, \\ P\{\xi = n/A_1\} &= pP\{\xi = n/A_1A_2\} + qP\{\xi = n - 2\}, \\ P\{\xi = n/A_1A_2\} &= pP\{\xi = n - 1/A_1A_2\} + qP\{\xi = n/A_1A_2\bar{A}_3\}, \\ P\{\xi = n/A_1A_2\bar{A}_3\} &= pP\{\xi = n - 3/A_1A_2\} + qP\{\xi = n/A_1A_2\bar{A}_3\bar{A}_4\}, \\ P\{\xi = n/A_1A_2\bar{A}_3\bar{A}_4\} &= pP\{\xi = n/\varepsilon\} + qP\{\xi = n - 5\}, \end{aligned} \tag{1}$$

$$P\{\xi = n\} = 0,$$

$$\text{при } n \leq 4, \text{ и } P\{\xi = n/\varepsilon\} = \begin{cases} 1, & \text{если } n = 5, \\ 0, & \text{если } n \neq 5 \end{cases}.$$

$$P\{\xi = n/A_1A_2\} = pP\{\xi = n - 1/A_1A_2\} + qp^2P\{\xi = n - 3/A_1A_2\} + \\ + q^2p^2P\{\xi = n - 2/A_1A_2\} + q^2pP\{\xi = n/\varepsilon\} + q^3P\{\xi = n - 5\}. \quad (2)$$

Если же $n \leq 2$, то $P\{\xi = n/A_1A_2\} = 0$. Используя (1) и (2), находим $P\{\xi = n\}$.

Найдем моменты первого и второго порядка случайной величины ξ . Из Теоремы 4 получаем:

$$E\xi = pE(\xi/A_1) + qE(\xi + 1)$$

$$E(\xi/A_1) = pE(\xi/A_1A_2) + qE(\xi + 2)$$

$$E(\xi/A_1A_2) = pE(\xi + 1/A_1A_2) + qE(\xi/A_1A_2\bar{A}_3)$$

$$E(\xi/A_1A_2\bar{A}_3) = pE(\xi + 3/A_1A_2) + qE(\xi/A_1A_2\bar{A}_3\bar{A}_4) \quad (3)$$

$$E(\xi/A_1A_2\bar{A}_3\bar{A}_4) = p \cdot 5 + qE(\xi + 5)$$

Отсюда:

$$E\xi = \frac{1}{p^3q^2}(1 + p^2 - 4p^3 + p^4)$$

Для момента второго порядка имеем систему:

$$E\xi^2 = pE(\xi^2 | A_1) + qE(\xi + 1)^2,$$

$$E(\xi^2 | A_1) = pE(\xi^2 | A_1A_2) + qE(\xi + 2)^2$$

$$E(\xi^2 | A_1A_2) = pE((\xi + 1)^2 | A_1A_2) + qE(\xi^2 | A_1A_2\bar{A}_3), \quad (4)$$

$$E(\xi^2 | A_1A_2\bar{A}_3) = pE((\xi + 3)^2 | A_1) + qE(\xi^2 | A_1A_2\bar{A}_3\bar{A}_4),$$

$$E(\xi^2 | A_1A_2\bar{A}_3\bar{A}_4) = 25p + qE(\xi + 5)^2.$$

Используя системы (3) и (4) находим момент второго порядка.

Найдем производящую функцию $\phi_\xi(z) = Ez^\xi$. По Теореме 5 имеем:

$$Ez^\xi = pE(z^\xi | A_1) + qEz^{\xi+2},$$

$$E(z^\xi | A_1) = pE(z^\xi | A_1A_2) + qEz^{\xi+2},$$

$$E(z^\xi | A_1A_2) = pE(z^{\xi+1} | A_1A_2) + qE(z^\xi | A_1A_2\bar{A}_3),$$

$$E(z^\xi | A_1A_2\bar{A}_3) = pE(z^{\xi+3} | A_1) + qE(z^\xi | A_1A_2\bar{A}_3\bar{A}_4),$$

$$E(z^\xi | A_1A_2\bar{A}_3\bar{A}_4) = z^5p + qEz^{\xi+5}.$$

Отсюда получаем:

$$\phi_\xi(z) = \frac{p^3q^2z^5}{1 - z + p^2q^2z^4 - p^2q^3z^5}$$

2.5 Программная реализация метода Зуева (Python)

Метод Зуева позволяет находить вероятности через решение системы линейных уравнений (или, эквивалентно, через разложение производящей функции). Ниже представлена реализация для примера $AA\bar{A}\bar{A}A$.

```

1 import numpy as np
2
3 def solve_zuev_system(n, p):
4     """
5     Решение системы линейных уравнений для серии $A A \bar{A} \bar{A} A$.
6     Находит точное значение P(xi = n).
7     """
8     q = 1 - p
9
10    # Используем формулу для phi(z) = N(z) / D(z)
11    # для нахождения коэффициентов ряда Тейлора.
12    # Паттерн: A A notA notA A
13    # Вероятность P(S) = p^3 * q^2
14    #
15    # N(z) = P(S) * z^5 = p^3 * q^2 * z^5
16    #
17    # Для знаменателя анализируем перекрытия (автокорреляцию):
18    # Сдвиг 1 (len 4): A notA notA A vs A A notA notA -> Нет совпадения
19    # Сдвиг 2 (len 3): notA notA A vs A A notA -> Нет совпадения
20    # Сдвиг 3 (len 2): notA A vs A A -> Нет совпадения
21    # Сдвиг 4 (len 1): A vs A -> Совпадение!
22    #
23    # Вклад от сдвига 4: val = P(S)/P(prefix_1) = (p^3 q^2) / p = p^2 q^2

```



```

24 # D(z) = (1-z)(1 + p^2 q^2 z^4) + p^3 q^2 z^5
25 # D(z) = 1 - z + p^2 q^2 z^4 - p^2 q^3 z^5
26
27 N_poly = np.zeros(6)
28 N_poly[5] = p**3 * q**2
29
30 D_poly = np.zeros(6)
31 D_poly[0] = 1
32 D_poly[1] = -1
33 D_poly[2] = 0 # Нет перекрытия на сдвиге 2
34 D_poly[3] = 0 # Нет перекрытия на сдвиге 3
35 D_poly[4] = (p**2)*(q**2)
36 D_poly[5] = -(p**2)*(q**3)
37
38 # Коэффициенты ряда: coeff[n] = (1/D[0]) * (N[n] - sum(D[k]*coeff[n-k]))
39 coeffs = np.zeros(n + 1)
40
41 for i in range(1, n + 1):
42     # Вклад от числителя (если есть степень i)
43     val = N_poly[i] if i < 6 else 0
44
45     # Вычитаем свертку знаменателя и уже найденных k-тов
46     convolution = 0
47     for k in range(1, 6):
48         if i - k >= 0:
49             convolution += D_poly[k] * coeffs[i-k]
50
51     coeffs[i] = (val - convolution) / D_poly[0]
52
53     return coeffs[n]
54
55 # Параметры
56 n = 100
57 p = 0.5
58 prob_exact_n = solve_zuev_system(n, p)
59 print(f"Вероятность наступления серии ровно в момент n={n}: {prob_exact_n:.6e}")
60
61 # Суммируем вероятности первого наступления от 5 до n
62 total_prob = 0
63 for t in range(5, n + 1):
64     total_prob += solve_zuev_system(t, p)
65
66 print(f"P(Ln >= 5) при n={n} (сумма p(t)): {total_prob:.6f}")

```

Листинг 1: Реализация метода Зуева на Python для ААААА

Результат работы программы:

Вероятность наступления серии ровно в момент n=100: 1.327180e-03

$P(L_n \geq 5)$ при $n=100$ (сумма $p(t)$): 0.961600

ГЛАВА 3. АСИМПТОТИЧЕСКИЙ АНАЛИЗ ХАРАКТЕРИСТИК СЕРИЙ

3.1 Дуальность между числом серий и временем ожидания

Между числом серий $N_{n,k}$ и временем ожидания $T_{m,k}$ m -й серии существует фундаментальная связь:

$$\{T_{m,k} \leq n\} \iff \{N_{n,k} \geq m\} \quad (6)$$

Это позволяет переносить все асимптотические результаты для числа серий на время ожидания.

3.2 Аппроксимация редких событий

Wang & Ji (1995) исследовали предельное поведение распределения числа серий успехов длины k . Доказано, что если вероятность серии мала (режим редких событий), то предельное распределение зависит от структуры испытаний.

Пусть $n \rightarrow \infty$ и $p \rightarrow 0$ таким образом, что $E(N_{n,k}) \rightarrow \lambda$.

1. Для **независимых испытаний** (i.i.d.) распределение числа серий сходится к **распределению Пуассона** с параметром λ . Это классический закон малых чисел.
2. Для **марковских испытаний** ситуация сложнее. Серии имеют тенденцию появляться «сгустками» (clustering). Если происходит серия успехов, вероятность следующей серии повышается из-за марковской зависимости. В этом случае предельным является **Сложное распределение Пуассона (Compound Poisson)** порядка k . Это связано с нарушением условия ординарности потока событий: события (серии) больше не являются изолированными.

3.3 Асимптотическая нормальность

Stefanov (2000) показал, что вектор статистик серий различных длин $(N_{n,1}, \dots, N_{n,k})$ принадлежит классу экспоненциальных семейств стохастиче-

ческих процессов (Exponential Family). Это свойство позволяет применять мощный аппарат предельных теорем для экспоненциальных семейств.

При фиксированной вероятности успеха $p \in (0, 1)$ (не стремящейся к нулю) и $n \rightarrow \infty$ совместное распределение нормированного вектора числа серий асимптотически нормально:

$$\frac{\mathbf{N}_n - n\boldsymbol{\mu}}{\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, \Sigma), \quad (7)$$

где $\boldsymbol{\mu}$ — вектор средних значений, а Σ — ковариационная матрица, элементы которой могут быть вычислены через параметры вложенной цепи Маркова.

3.4 Большие отклонения для самой длинной серии

Fu, Wang и Lou (2003) исследовали поведение самой длинной серии L_n в последовательности из n испытаний. Для анализа вероятности того, что L_n не превысит заданное значение k (для больших n), они использовали метод спектрального анализа матрицы перехода.

Пусть N^* — матрица перехода вложенной цепи Маркова, из которой исключено поглощающее состояние (соответствующее появлению серии длины k). Согласно теореме Перрона-Фробениуса, у этой неотрицательной матрицы существует максимальное положительное собственное число λ_1 , которое строго больше модуля всех остальных собственных чисел.

Вероятность того, что длина максимальной серии меньше k , ведет себя как:

$$P(L_n < k) \sim c \cdot \lambda_1^n, \quad \text{при } n \rightarrow \infty. \quad (8)$$

Это соотношение позволяет получить результат для больших отклонений:

$$\lim_{n \rightarrow \infty} \frac{1}{n} \log P(L_n < k) = \log \lambda_1 = -\beta, \quad (9)$$

где $\beta > 0$. Это означает, что вероятность хвоста распределения убывает экспоненциально со скоростью, определяемой спектральным радиусом усеченной матрицы перехода. Данный результат справедлив как для независимых испытаний, так и для цепей Маркова.

ГЛАВА 4. СТАТИСТИЧЕСКИЕ ПРИЛОЖЕНИЯ И ВЫЧИСЛИТЕЛЬНЫЕ АЛГОРИТМЫ

4.1 Тесты на случайность: мощность и условные распределения

Классические тесты на случайность (например, критерий Вальда-Вольфовица) часто используют нормальную аппроксимацию для условного распределения числа серий R при фиксированном числе успехов n_1 . Однако Lou (1997) показала, что при $n_1/n \rightarrow 0$ или 1 (когда число успехов или неудач мало по сравнению с общей длиной последовательности), распределение становится сильно асимметричным, и нормальная аппроксимация дает значительную ошибку, особенно на «хвостах» распределения.

Использование метода FMCI позволяет вычислить **точное** условное распределение без асимптотических допущений:

$$P(R = r \mid S_n = n_1) = \frac{P(R = r, S_n = n_1)}{P(S_n = n_1)}, \quad (10)$$

где совместная вероятность в числителе находится через вложение в цепь Маркова, отслеживающую одновременно число серий и число успехов. Это существенно повышает точность тестирования гипотез для малых выборок или редких событий.

4.2 Сравнение статистик перекрывающихся и неперекрывающихся серий

Koutras и Alexandrou (1997) провели анализ мощности тестов, основанных на различных типах подсчета серий, против специфических альтернатив:

- **Марковская зависимость (кластеризация):** Если альтернативная гипотеза предполагает наличие «сгустков» (clusters) единиц, то статистика перекрывающихся серий $M_{n,k}$ (Ling's counting) обладает наивысшей мощностью. Она лучше улавливает плотные группы событий, так как одна длинная серия дает большой вклад в статистику $M_{n,k}$.
- **Периодичность или регулярность:** Статистика неперекрывающихся серий $N_{n,k}$ (Feller's counting) работает лучше против альтернатив, свя-

занных с регулярным появлением событий, так как она «сбрасывает» счетчик и требует нового начала формирования серии.

Таким образом, выбор типа статистики серий должен диктоваться предполагаемым характером нарушения случайности.

4.3 Программная реализация метода FMCI (Python)

Ниже приведен код, реализующий вычисление вероятности появления серии (статистика L_n) методом FMCI.

```
1 import numpy as np
2
3 def run_probability_fmci(n, k, p):
4     """
5     Вычисление вероятности появления серии успехов длины k
6     в n испытаниях методом вложения в цепь Маркова.
7     """
8     q = 1 - p
9     dim = k + 1
10    # Инициализация матрицы перехода
11    M = np.zeros((dim, dim))
12    for i in range(k):
13        M[i, 0] = q        # Сброс при неудаче
14        M[i, i+1] = p      # Рост серии при успехе
15    M[k, k] = 1.0          # Поглощающее состояние
16
17    # Начальный вектор (состояние 0)
18    pi_0 = np.zeros(dim)
19    pi_0[0] = 1.0
20
21    # Вычисление: pi_n = pi_0 * M^n
22    M_n = np.linalg.matrix_power(M, n)
23    pi_n = np.dot(pi_0, M_n)
24
25    return pi_n[k]
26
27 # Параметры
28 n = 100
29 k = 5
30 p = 0.5
31 print(f"P(Ln >= {k}) при n={n}: {run_probability_fmci(n, k, p):.6f}")
```

Листинг 2: Реализация метода FMCI на Python

Результат работы программы:

$P(L_n \geq 5)$ при $n=100$: 0.810110

ГЛАВА 5. ЗАКЛЮЧЕНИЕ

В рамках данной курсовой работы было проведено комплексное исследование характеристик времени наступления серий событий (run statistics), включающее сравнительный анализ алгебраических методов, изучение асимптотического поведения и рассмотрение статистических приложений. Основные выводы работы можно сформулировать следующим образом:

1. Сравнительный анализ аналитических методов:

- **Метод вложения в конечную цепь Маркова (FMCI):** Продемонстрировал высокую универсальность для численного нахождения распределений на конечных интервалах n . Однако вычислительная сложность метода напрямую зависит от размерности пространства состояний, что делает его громоздким при анализе сложных паттернов с большим периодом.
- **Метод рекуррентных линейных уравнений (метод Зуева):** Показал себя как мощный аналитический инструмент, дополняющий матричный подход. Главным преимуществом является сведение задачи поиска моментов и производящих функций к решению системы линейных уравнений размерности k (длина серии), что вычислительно эффективнее операций с большими переходными матрицами. Полученные явные выражения для производящих функций в виде рациональных дробей $\phi_\xi(z) = \frac{N(z)}{D(z)}$ позволяют находить вероятности через коэффициенты ряда Тейлора, избегая прямого перемножения матриц.

2. Асимптотический анализ и предельные теоремы:

- Подтверждена фундаментальная двойственность между распределением числа серий $N_{n,k}$ и временем ожидания m -й серии $T_{m,k}$, что позволяет переносить предельные результаты с одной статистики на другую.
- В режиме *редких событий* ($p \rightarrow 0$) показано, что для независимых испытаний распределение числа серий сходится к распределению Пуассона. Однако при наличии марковской зависимости

(корреляции между испытаниями) пределом является **сложное распределение Пуассона** (Compound Poisson), что объясняется эффектом кластеризации — тенденцией серий появляться группами («сгустками»).

- Для самой длинной серии L_n установлено, что скорость убывания «хвостов» распределения подчиняется принципу больших уклонений и определяется спектральным радиусом усеченной матрицы перехода.

3. Статистические приложения и мощность критериев:

- Продемонстрирована несостоятельность нормальной аппроксимации при малых выборках или вероятностях успеха, близких к границам интервала $(0, 1)$. В этих случаях использование точных распределений, полученных методами FMCI или Зуева, является критически важным для корректной оценки уровня значимости тестов.
- Выявлена зависимость мощности статистических критериев от способа подсчета серий:
 - Статистика **перекрывающихся серий** ($M_{n,k}$, счет по Лингу) обладает наивысшей мощностью против альтернатив, предполагающих *кластеризацию* ошибок или событий (марковская зависимость).
 - Статистика **неперекрывающихся серий** ($N_{n,k}$, счет по Феллеру) эффективнее выявляет нарушения случайности, связанные с *периодичностью* или жесткой регулярностью структуры.

4. **Программная реализация:** Разработанный программный комплекс на языке Python подтвердил теоретические выкладки. Реализация метода Зуева через символьные вычисления и разложение полиномов показала высокую точность (10^{-6}) и совпадение с результатами матричного метода FMCI, что верифицирует корректность обоих подходов.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Зуев, Н. М. Моменты и распределение времени наступления серии случайных событий в испытаниях Бернулли / Н. М. Зуев // Вестник БГУ. Сер. 1, Физика. Математика. Информатика.
2. Зуев, Н. М. Распределение времени наступления серии случайных событий в полиномиальной схеме / Н. М. Зуев // Вестник БГУ. Сер. 1, Физика. Математика. Информатика.
3. Феллер, В. Введение в теорию вероятностей и её приложения. Т.1 / В. Феллер. – М.: Мир, 1967. – 498 с.
4. Doi, M. On the joint distribution of runs in a sequence of multi-state trials / M. Doi, E. Yamamoto // Statistics & Probability Letters. – 1998. – Vol. 39. – P. 133–141.
5. Fu, J. C. Distribution theory of runs and patterns associated with a sequence of multi-state trials / J. C. Fu // Statistica Sinica. – 1996. – Vol. 6. – P. 957–974.
6. Fu, J. C. Distribution theory of runs: a Markov chain approach / J. C. Fu, M. V. Koutras // Journal of the American Statistical Association. – 1994. – Vol. 89. – P. 1050–1058.
7. Fu, J. C. On exact and large deviation approximation for the distribution of the longest run in a sequence of two-state Markov dependent trials / J. C. Fu, L. Wang, W. Y. W. Lou // Journal of Applied Probability. – 2003. – Vol. 40. – P. 346–360.
8. Han, Q. Formulae and recursions for the joint distributions of success runs of several lengths in a two-state Markov chain / Q. Han, S. Aki // Statistics & Probability Letters. – 1998. – Vol. 40. – P. 203–214.
9. Han, Q. Distributions and probability generating functions of success run vector / Q. Han // Far East Journal of Theoretical Statistics. – 2002. – Vol. 6(1). – P. 57–72.

10. Hirano, K. On number of occurrences of success runs of specified length in a two-state Markov chain / K. Hirano, S. Aki // *Statistica Sinica*. – 1993. – Vol. 3. – P. 313–320.
11. Jennen-Steinmetz, C. The asymptotic power of runs tests / C. Jennen-Steinmetz, T. Gasser // *Scandinavian Journal of Statistics*. – 1986. – Vol. 13. – P. 263–269.
12. Koutras, M. V. Non-parametric randomness tests based on success runs of fixed length / M. V. Koutras, V. A. Alexandrou // *Statistics & Probability Letters*. – 1997. – Vol. 32. – P. 393–404.
13. Lou, W. Y. W. An application of the method of finite Markov chain imbedding to runs tests / W. Y. W. Lou // *Statistics & Probability Letters*. – 1997. – Vol. 31. – P. 155–161.
14. Stefanov, V. T. On run statistics for binary trials / V. T. Stefanov // *Journal of Statistical Planning and Inference*. – 2000. – Vol. 87. – P. 177–185.
15. Wang, Y. H. Limit theorems for the number of occurrences of consecutive k successes in n Markovian trials / Y. H. Wang, S. Ji // *Journal of Applied Probability*. – 1995. – Vol. 32. – P. 727–735.